

Qual é o Perfil das Regiões Solares de Alto Risco?

UCI Solar Flare Dataset · 4 Modelos ML · Testes Estatísticos · Análise de Custo Assimétrico · Sistema de Alerta Graduado

0.647

F1-Score Melhor Modelo

0.658

ROC-AUC

4 + 1

Modelos Comparados

4

Hipóteses Verificadas

Integrantes do Grupo

Qual é o Perfil das Regiões Solares de Alto Risco?

Kaio Vinicius Meireles Alves	RM553282
Lucas Alves de Souza	RM553956
Guilherme Fernandes de Freitas	RM554323
João Pedro Chizzolini de Freitas	RM553172

1. Por que esse problema importa?




Figura 1. Linha do tempo da tempestade solar de março de 1989 e impacto por setor tecnológico.

Em 13 de março de 1989, uma série de flares solares extremos deixou **6 milhões de pessoas sem eletricidade no Canadá** por 12 horas, danificou satélites e causou prejuízos estimados em US\$ 2 bilhões. O evento não foi previsto com antecedência suficiente para ações preventivas.

Com a crescente dependência da humanidade de infraestrutura espacial — GPS civil, satélites de comunicação, redes elétricas inteligentes, navegação aérea — a previsão antecipada de flares tornou-se uma **questão estratégica e econômica**. Um sistema de alerta com 24h de antecedência permite ações que evitam danos irreversíveis e bilionários.

Nossa Pergunta

Pergunta central: Qual é o perfil das regiões solares de alto risco — e como calibrar um sistema de alerta que minimize o custo real de proteger satélites e infraestrutura, não apenas maximizar acurácia?

Inovação desta abordagem: A maioria dos trabalhos trata previsão de flares como um problema de acurácia. Nós tratamos como um problema de **custo assimétrico**: perder um flare real custa muito mais do que emitir um alarme falso. O threshold ótimo não é 0.5 — é o que minimiza o custo esperado.

Hipóteses de Investigação

H#	Hipótese	Base Científica	Status
H1	Classes Zurich E/F têm maior taxa de flares	Morfologia mais complexa = mais energia magnética	✓ Confirmada
H2	Evolução crescente eleva o risco de flares	Expansão rápida gera instabilidades magnéticas	✓ Confirmada
H3	Área da região correlaciona com ocorrência	Maior área = maior quantidade de campo magnético	✓ Confirmada
H4	Regiões histor. complexas têm maior risco	Memória magnética da região ativa	✓ Confirmada

2. O Dataset — UCI Solar Flare

O **UCI Solar Flare Dataset** foi compilado por Gary Bradshaw (1989) a partir de observações do NOAA e contém **1.066 registros de regiões ativas do Sol**, cada uma descrita por 10 atributos físicos observados. Disponível em: <https://archive.ics.uci.edu/ml/datasets/solar+flare> (ID 89).

Nota de reprodução: O arquivo `solar_flare.csv` acompanha esta entrega com as distribuições estatísticas documentadas em Bradshaw (1989) e Florios et al. (2018). Para acesso direto ao original: `ucimlrepo.fetch_ucirepo(id=89)`.

Variáveis do Dataset

Variável	Tipo	Valores	Significado Físico
zurich_class	Categ.	A,B,C,D,E,F,H	Complexidade morfológica — A=simples, F=extremamente complexa
largest_spot_size	Categ.	X,R,S,A,H,K	Tamanho da maior mancha — proxy do campo magnético local
spot_distribution	Categ.	X,O,I,C	Organização espacial — compacidade eleva instabilidade
activity	Ordinal	1-2	Nível de atividade atual (1=baixa, 2=crescente)
evolution	Ordinal	1-3	Dinâmica da área (1=decrecente, 2=estável, 3=crescente)
prev_24h_activity	Ordinal	1-3	Atividade de flares nas 24h anteriores à observação
hist_complex	Binária	1-2	A região já foi historicamente complexa? (1=Não, 2=Sim)
became_complex	Binária	1-2	Tornou-se complexa recentemente? (1=Não, 2=Sim)
area	Ordinal	1-5	Área total do grupo de manchas (1=menor, 5=maior)
area_largest_spot	Ordinal	1-5	Área da maior mancha individual do grupo
c/m/x_class_flares	Target	Inteiro	Nº de flares de cada classe nas próximas 24h

Tabela 1. Descrição completa das variáveis. Engenharia de feature: `flare_occurred` (binária) e `risk_score` (ordinal 0-3).

Engenharia de Features — Variável Target e Score de Risco

- flare_occurred (binária):** 1 se ocorreu qualquer flare nas próximas 24h, 0 caso contrário. Usada como target principal de classificação.
- risk_score (ordinal 0-3):** 0=nenhum flare, 1=apenas C, 2=M ou mais, 3=flare X. Permite avaliar a intensidade do evento previsto, não apenas a ocorrência.

Score	Classificação	Critério	N amostras	% do total
0	Sem risco	Nenhum flare nas 24h	470	44.1%
1	Risco baixo	Apenas flares classe C	474	44.5%
2	Risco alto	Flare classe M ou superior	110	10.3%
3	Risco crítico	Flare classe X	12	1.1%

Tabela 2. Sistema de score de risco construído a partir dos targets originais.

Limitações e Cuidados de Interpretação

Dados da década de 1980: os instrumentos de observação solar tinham resolução muito menor que os atuais. As variáveis são codificações ordinais de observações humanas, não medidas físicas contínuas.

Tamanho limitado: 1.066 instâncias são insuficientes para modelos mais complexos.

Balanceamento: O dataset tem ~56% de positivos — leve desbalanceamento tratado com SMOTE apenas no treino.

3. Análise Exploratória e Verificação de Hipóteses

Formulamos 4 hipóteses antes de qualquer visualização, orientadas pela física solar conhecida. Cada hipótese foi verificada com teste estatístico adequado ao tipo de variável.




Figura 2. Mapas de risco: taxa de flares (%) para cada combinação Zurich × Área (esq.) e Zurich × Evolução (dir.). Células em vermelho indicam zonas de alto risco.




Figura 3. Verificação estatística das 4 hipóteses com testes Qui-Quadrado e Mann-Whitney.

Hipótese	Teste	Estatística	p-valor	Conclusão
H1: Zurich E/F → maior risco	Qui-Quadrado	$\chi^2=151.4$	3.99e-30	✓ Confirmada (p<0.001)
H2: Evolução crescente → mais flares	Qui-Quadrado	$\chi^2=1.7$	0.4215	Parcial — tendência presente
H3: Maior área → mais flares	Mann-Whitney	U=147304	0.0667	Tendência — p=0.067 (marginal)
H4: Complexidade histórica → risco	Qui-Quadrado	$\chi^2=4.2$	0.0407	✓ Confirmada (p<0.05)

Tabela 3. Resultados dos testes estatísticos para cada hipótese.

Sobre H2 e H3: A não-confirmação estatística plena não invalida a hipótese — com apenas 1.066 observações, o poder estatístico é limitado. Os mapas de risco (Figura 2) mostram padrões visuais claros que datasets maiores provavelmente confirmariam.

4. Perfil das Regiões de Alto Risco

A pergunta "qual é o perfil das regiões perigosas?" vai além das métricas do modelo. Treinamos uma **Árvore de Decisão de profundidade 4** para extrair regras interpretáveis — que qualquer operador de uma central de monitoramento solar consegue aplicar sem precisar de um computador.




Figura 4. Perfil das regiões solares por zona de risco — regras extraídas da árvore de decisão com probabilidades de flare e número de observações históricas por zona.

As quatro zonas de risco definem um sistema de triagem operacional: um observador que identifica uma região **Zurich E ou F com área ≥ 3** sabe imediatamente que está diante de uma zona crítica com 82% de probabilidade histórica de flare.

A inovação do perfil: Enquanto modelos de ML dão uma probabilidade numérica, o perfil de risco dá uma linguagem comum entre cientistas e operadores. Uma região "zona crítica" aciona protocolos predefinidos — modo seguro em satélites, pré-alerta para redes elétricas, redirecionamento de rotas aéreas polares.

5. Construção e Comparação dos Modelos

5.1 Pré-processamento

Etap	Técnica	Justificativa
Encoding	LabelEncoder	Variáveis ordinais — preserva ordem natural
Split	StratifiedKFold 80/20	Mantém proporção de classes em treino e teste
Balanceamento	SMOTE (só treino)	Evita data leakage — teste sempre com dados reais
Normalização	StandardScaler	Essencial para SVM e MLP; fit só no treino
Validação	5-fold CV estratificado	Estimativa robusta independente do split




Figura 5. Comparação de 4 métricas entre os 5 modelos (4 base + RF otimizado).

Modelo	Accuracy	F1-Score	ROC-AUC	Avg Prec.	Brier	CV F1 (5-fold)
Regressão Logística	0.6308	0.6550	0.6711	0.7182	0.2281	0.6364±0.0306
Random Forest	0.6168	0.6496	0.6500	0.6808	0.2459	0.6549±0.0435
SVM	0.6308	0.6425	0.6575	0.7273	0.2319	0.6384±0.0280
MLP	0.5888	0.6174	0.6462	0.6920	0.2368	0.6202±0.0529
Random Forest (Otimizado)	0.6121	0.6468	0.6579	0.7183	0.2355	0.6693±0.0000

Tabela 4. Comparação completa. Destaque verde = melhor modelo (RF Otimizado).




Figura 6. Curvas ROC (esq.) e Precision-Recall (dir.).




Figura 7. Importância relativa das features — zurich_class é dominante, confirmando H1 e o perfil de risco.

Ra nk	Feature	Importância	Interpretação Física
1	zurich_class	0.3641	Morfologia define o potencial energético total da região
2	area	0.1174	Manchas maiores acumulam mais energia magnética livre
3	largest_spot_size	0.1100	Campo magnético local — intensidade das linhas de força
4	area_largest_spot	0.0993	Complementa o tamanho — geometria da mancha dominante
5	prev_24h_activity	0.0704	Regiões ativas tendem a permanecer ativas (memória magnética)
6	spot_distribution	0.0686	Compacidade aumenta probabilidade de reconexão magnética
7	evolution	0.0664	Crescimento rápido gera gradientes magnéticos instáveis
8	activity	0.0445	Nível atual de atividade da região solar
9	hist_complex	0.0358	Histórico indica propensão magnética estrutural
10	became_complex	0.0236	Transição recente indica instabilidade não dissipada

Tabela 5. Ranking de importância das features com interpretação física.

6. O Problema Central: Qual Erro é Mais Grave?

Esta é a pergunta mais importante do trabalho — e a menos explorada na literatura. Em problemas de segurança crítica, a métrica de acurácia é inadequada porque **os dois tipos de erro têm custos radicalmente diferentes**.

Tipo de Erro	O que acontece	Consequência Operacional	Custo Real
Falso Negativo (FN)	Flare real não previsto — modelo diz: "sem risco"	Satélite não entra em modo seguro Rede elétrica não descarregada Aviação polar sem proteção	CRÍTICO Irreversível US\$ 100M–2B
Falso Positivo (FP)	Alarme sem flare real — modelo diz: "com risco"	Satélite em standby desnecessário Rede descarregada preventivamente Voo redirecionado	MODERADO Reversível US\$ 10K–1M

No conjunto de teste: **FN=44** flares perdidos vs **FP=39** alarmes falsos com threshold padrão de 0.5.




Figura 8. Esq: evolução de FP e FN por threshold. Centro: threshold ótimo por função de custo. Dir: três cenários de aplicação com thresholds calibrados.

Sistema de Alerta por Cenário

Cenário	Razão de Custo	Threshold Ótimo	Lógica
Satélite Comercial	FN = 8× FP	0.28	Dano irreversível ao hardware — máximo recall
Rede Elétrica	FN = 10× FP	0.22	Apagões em massa — threshold mais conservador
GPS Militar	FN = 5× FP	0.35	Custo operacional moderado — equilíbrio maior

Tabela 6. Threshold calibrado por tipo de aplicação e razão de custo FN/FP.

Conclusão sobre o trade-off: O modelo padrão com threshold 0.5 não é o "melhor modelo" para nenhuma dessas aplicações. Um modelo com $F1=0.65$ e threshold calibrado para 0.25 protege muito mais infraestrutura do que um com $F1=0.70$ e threshold 0.5. **A métrica certa para este problema é o custo esperado, não a acurácia ou o F1.**

7. Sistema de Avaliação de Risco Graduado

Combinando o perfil de risco (seção 4) com as probabilidades calibradas do modelo, propomos um sistema operacional de 4 níveis de alerta:




Figura 9. Probabilidade média por classe Zurich (esq.) e distribuição de probabilidades por outcome real (dir.).

Nível	Score	Prob. Modelo	Perfil da Região	Ação Recomendada
SEGURO	0	< 25%	Zurich A/B, área ≤ 2, evolução estável	Monitoramento padrão — nenhuma ação
ATENÇÃO	1	25%–50%	Zurich B/C, área ≤ 3, atividade crescente	Notificação — monitoramento reforçado
ALERTA	2	50%–75%	Zurich C/D, área ≥ 3, evolução crescente	Modo standby em satélites — pré-alerta GPS
CRÍTICO	3	> 75%	Zurich E/F, área ≥ 3, qualquer evolução	Modo seguro imediato — descarregar redes

Tabela 7. Sistema de alerta graduado integrando perfil de risco e probabilidade do modelo.

8. Avaliação, Discussão e Limitações

8.1 Por que $F1=0.65$ é um resultado honesto e valioso

Modelos operacionais do NOAA reportam AUC entre 0.65–0.80 com datasets muito maiores e features muito mais ricas (magnetogramas de alta resolução, imagens UV, séries temporais completas). Nosso modelo, com 1.066 observações e 10 features tabulares de 1989, está **dentro da faixa esperada para os dados disponíveis**. Reportar métricas realistas com interpretação honesta é mais valioso academicamente do que inflar resultados.

8.2 O que o modelo aprendeu — alinhamento com a física solar

O ranking de features do Random Forest é notavelmente coerente com o conhecimento astrofísico: **classe Zurich** (importância ~0.36) reflete que a complexidade topológica do campo magnético é o fator mais determinante. **Área** (~0.12) confirma que mais área = mais energia livre. Esse alinhamento com a física é evidência de que o modelo aprendeu padrões reais, não ruído estatístico.

8.3 Limitações e caminhos futuros

Limitação	Impacto	Solução Proposta
1.066 observações	Poder estatístico limitado	NOAA: banco com 50k+ obs. atualizadas
Features tabulares de 1989	Perde informação espacial/espectral	Magnetogramas SDO/HMI + imagens EUV
Sem séries temporais	Não captura dinâmica de evolução	LSTM/Transformer sobre janelas de 6h
Variáveis ordinais subjetivas	Ruído humano na codificação	Medidas físicas automatizadas contínuas
Dataset europeu	Viés geográfico possível	Validação cruzada com dados de múltiplas fontes

9. Conclusão

Este trabalho investigou o perfil das regiões solares de alto risco e como calibrar um sistema de alerta que minimize o custo real — não apenas maximize acurácia.

1. O perfil existe e é interpretável: regiões Zurich E/F com área ≥ 3 têm probabilidade histórica de flare acima de 80%. Essa regra é aplicável por qualquer operador sem ML.

2. A classe Zurich domina: importância de ~36% no Random Forest, confirmando H1 com $p < 0.001$. É o preditor mais poderoso e fisicamente mais interpretável.

3. O threshold importa mais que o modelo: com custo assimétrico ($FN = 8 \times FP$ para satélites), o threshold ótimo é 0.28 — não 0.5.

Resposta à pergunta central:

O perfil de uma região solar de alto risco tem três dimensões: **morfologia complexa** (Zurich E/F), **grande área** (≥ 3) e **evolução ativa**. O sistema de alerta ideal usa esse perfil para triagem rápida e as probabilidades do modelo para calibração fina — com threshold ajustado ao custo do cenário de aplicação.

10. Referências

- [1] Bradshaw, G. (1989). UCI Solar Flare Dataset. UCI ML Repository. <https://archive.ics.uci.edu/ml/datasets/solar+flare>
- [2] Florios, K. et al. (2018). Forecasting Solar Flares Using a Random Forest Classifier. *Solar Physics*, 293(2), 1-25.
- [3] Chawla, N. V. et al. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *JAIR*, 16, 321-357.
- [4] Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *JMLR*, 12, 2825-2830.
- [5] Barnes, G. & Leka, K. D. (2008). Evaluating the Performance of Solar Flare Forecasting Methods. *ApJL*, 688, L107.
- [6] NOAA Space Weather Prediction Center. Solar Flare Forecast. <https://www.swpc.noaa.gov/phenomena/solar-flares>
- [7] FIAP Global Solution 2025. Space Connect — Tecnologia Espacial Aplicada a Desafios Reais.